CÓMPUTO PARALELO

Detección Paralela de Apnea del Sueño

Fase 2.- Detección Paralela de Apnea del Sueño: Análisis de Speedup y Extracción de Descriptores Fisiológicos mediante Aprendizaje Clásico en CPU

Jassiel Luna Cantu
Instituto Politécnico Nacional

Juan Daniel García Román
Instituto Politécnico Nacional

Problema y propuesta

El Problema Clínico y la Alternativa

- La apnea obstructiva del sueño (AOS) es grave y su diagnóstico estándar (polisomnografía) es costoso, invasivo y poco accesible.
- El ECG de una sola derivación es la alternativa ideal por ser una señal simplificada y altamente informativa, compatible con dispositivos portátiles.

El Hueco en el Estado del Arte.

- La literatura se divide en dos extremos problemáticos: modelos de Deep Learning opacos que exigen el uso de GPUs, y modelos clásicos que ignoran por completo la latencia de procesamiento.
- El cálculo de descriptores no lineales esenciales, como la Entropía Muestral (SampEn), tiene una complejidad temporal cuadrática O(N^2).

La Propuesta

- Se propone una arquitectura concurrente y modular ejecutada enteramente en CPU.
- El pipeline divide las señales en épocas independientes de 60 segundos y utiliza un despachador nativo con el módulo multiprocessing de Python.
- Esta estrategia evade el Bloqueo Global del Intérprete (GIL) y paraleliza la extracción de la SampEn y la FFT.



Conjunto de Datos y Justificación del Desbalance

Datos y volumen

Se utilizaron los 35 registros de entrenamiento de la base Apnea-ECG de PhysioNet.

Tras el preprocesamiento, se consolidaron 16,892 ventanas válidas e independientes de 60 segundos.

La distribución de las etiquetas presenta un desbalance claro: 10,393 ventanas corresponden a respiración normal (61.5%) y 6,499 a eventos de apnea (38.5%).

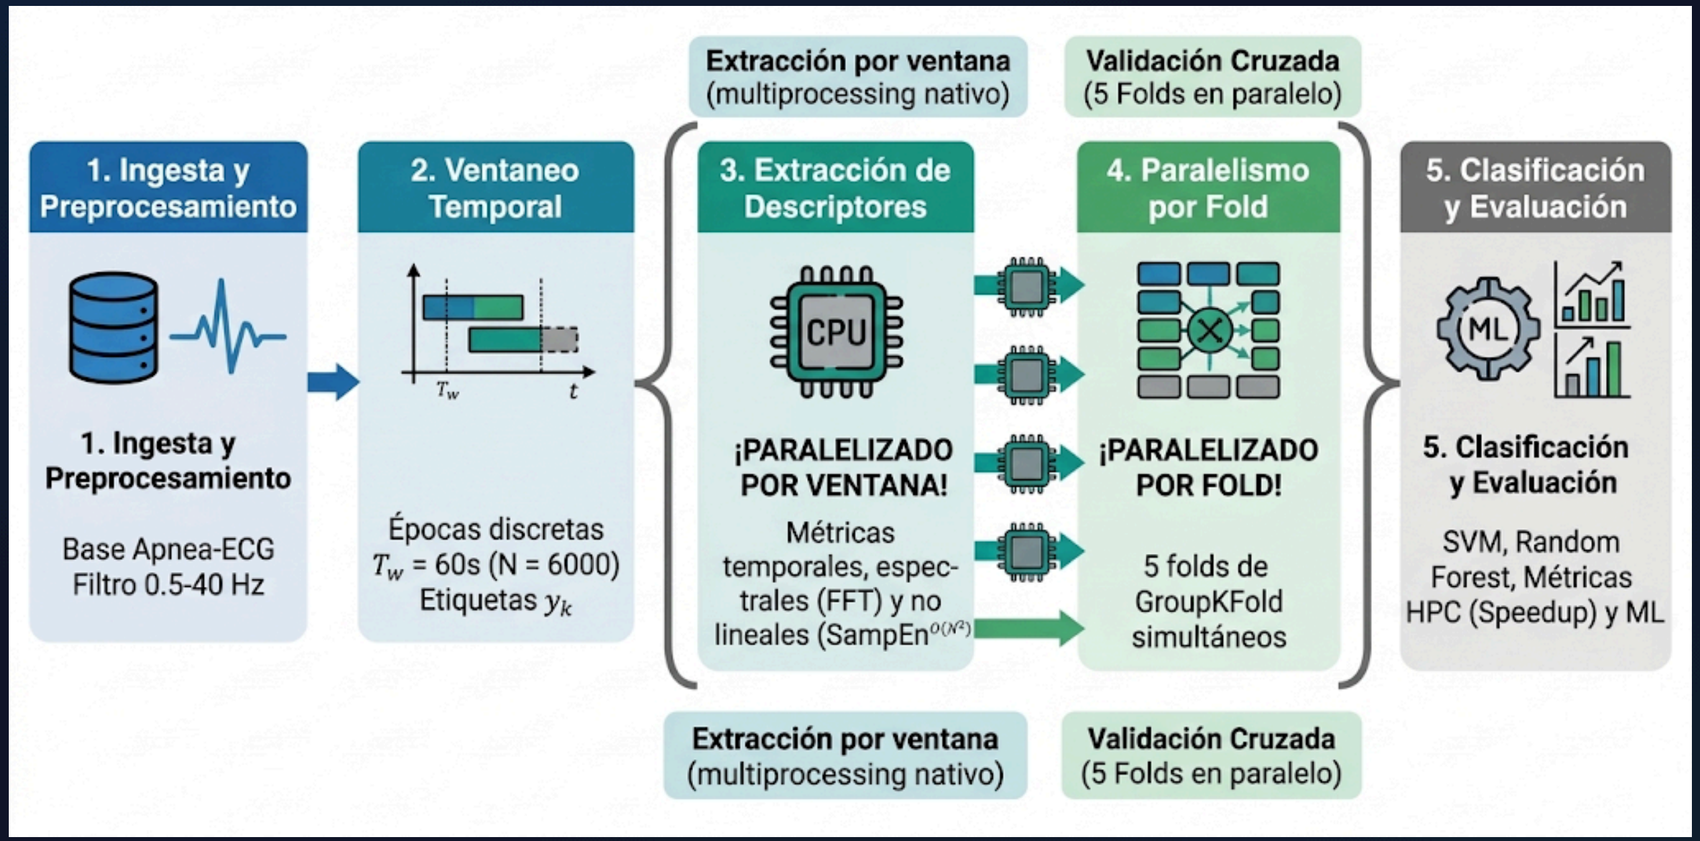
Uso de class_weight="balanced"

El sesgo estadístico: Al existir casi el doble de casos normales, los algoritmos clásicos de Machine Learning tienden a favorecer a la clase mayoritaria para inflar su métrica de Exactitud (Accuracy).

El costo clínico de los Falsos Negativos: En un contexto de tamizaje o cribado médico, omitir eventos reales (baja sensibilidad) es un error crítico y costoso para el paciente.

La solución: El argumento asigna penalizaciones inversamente proporcionales a la frecuencia de cada clase.

Metodología



Extracción de 11 Descriptores Fisiológicos

Dominio temporal

- Serie RR: Media, varianza, asimetría, curtosis y número total de intervalos RR.
- Señal de ECG: Tasa de cruces por cero (ZCR).

Dominio Frecuencial:

- Análisis mediante FFT: Potencia integrada en las bandas de muy baja frecuencia (VLF), baja frecuencia (LF) y alta frecuencia (HF).
- Balance simpaticovagal: Cociente LF/HF calculado sobre la serie RR interpolada a 4 Hz.

Dinamica no lineal:

- Entropía Muestral (SampEn): Evalúa la complejidad y predictibilidad de las 6000 muestras continuas de la ventana.
- Impacto computacional: Al comparar exhaustivamente las parejas de subsecuencias, genera una complejidad temporal de O(N^2).



Desempeño Diagnóstico: Validación por Paciente

- Problema de desbalance
- Impacto en la ponderación
- Validación Estricta

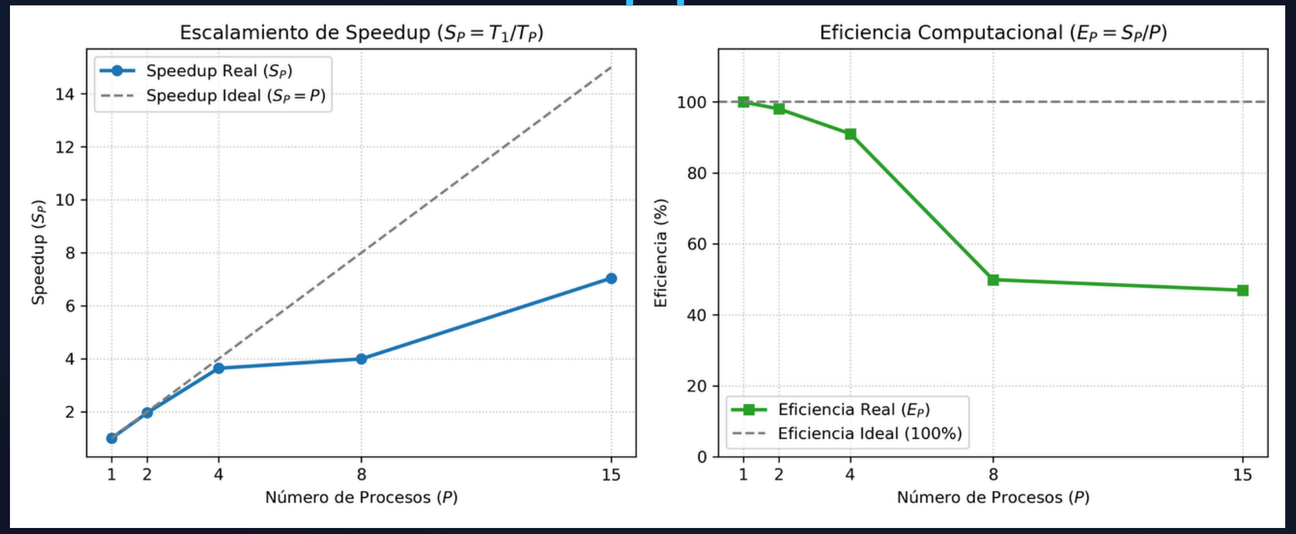
Modelo	Exactitud	Recall (Sensibilidad)	F1-Score
SVM (RBF)	71.3%	53.7%	0.590
SVM (RBF, balanced)	69.9%	66.9%	0.631
Random Forest	74.4%	57.4%	0.633
Random Forest (balanced)	**76.1%**	**67.9%**	**0.686**

Rendimiento Computacional: Speedup y Eficiencia

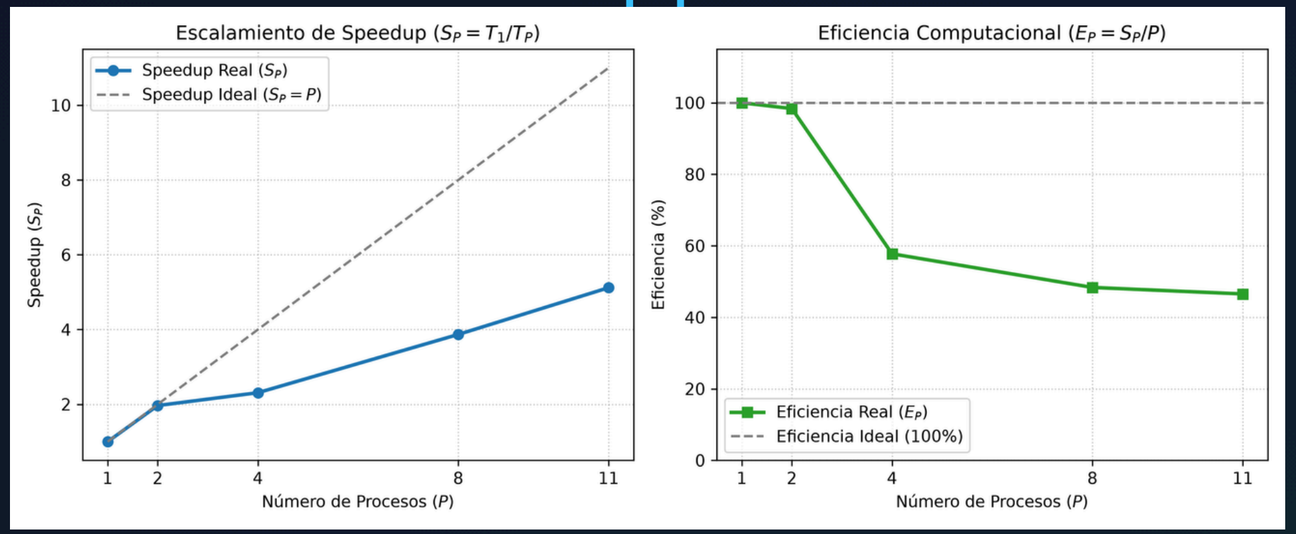
Impacto del Procesamiento Concurrente

- Reducción de latencia: El procesamiento nativo por ventanas redujo el tiempo de extracción de forma drástica, pasando de 288 segundos en ejecución secuencial a solo 41 segundos en paralelo para procesar el lote de pruebas.
- Escalamiento alcanzado: Se logró un speedup máximo de 7.04x utilizando 15 procesos en el Equipo A, y una aceleración de 5.12x con 11 procesos en el Equipo B.
- Comportamiento de la eficiencia: El escalamiento fue casi lineal hasta los 4 procesos; al superar la cantidad de núcleos físicos y usar los hilos lógicos, la eficiencia computacional se estabilizó cerca del 47% en ambas máquinas.

Equipo A

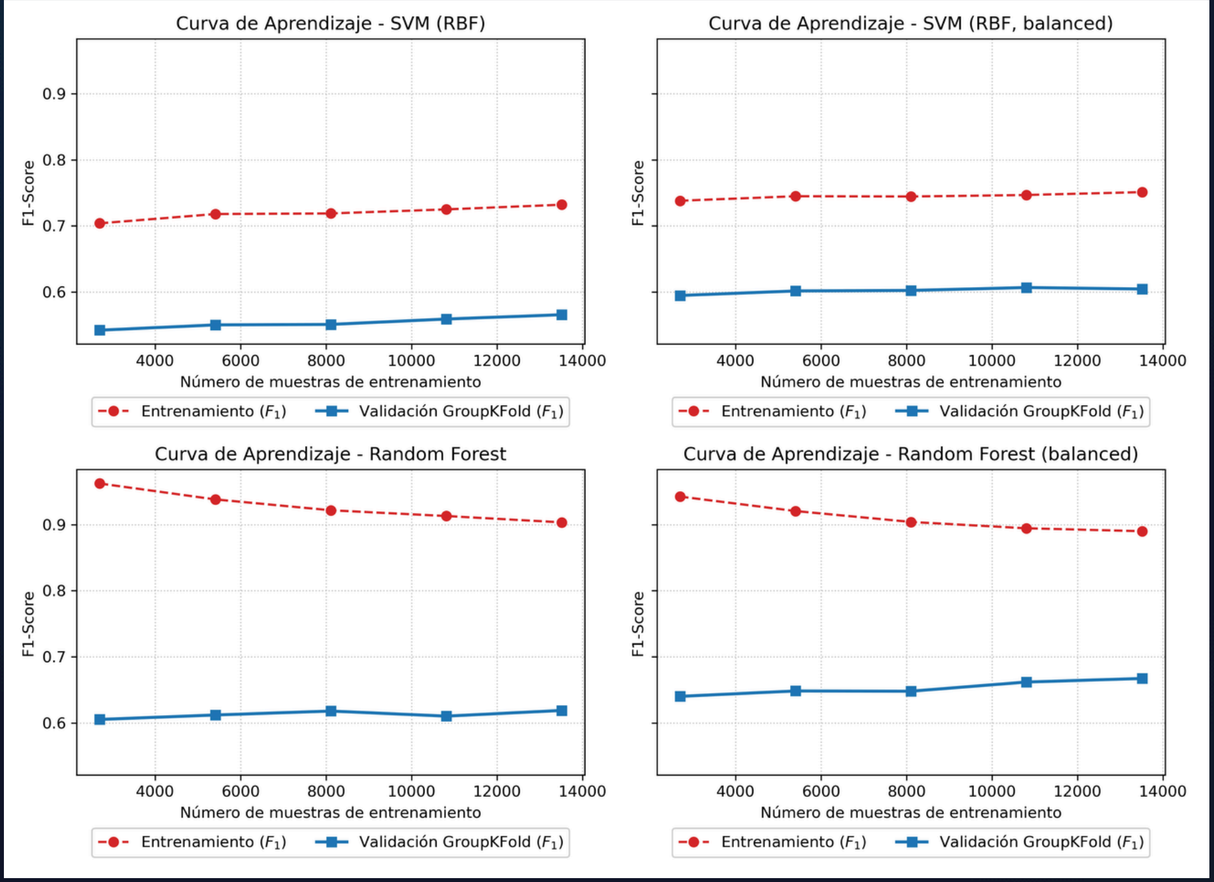


Equipo B

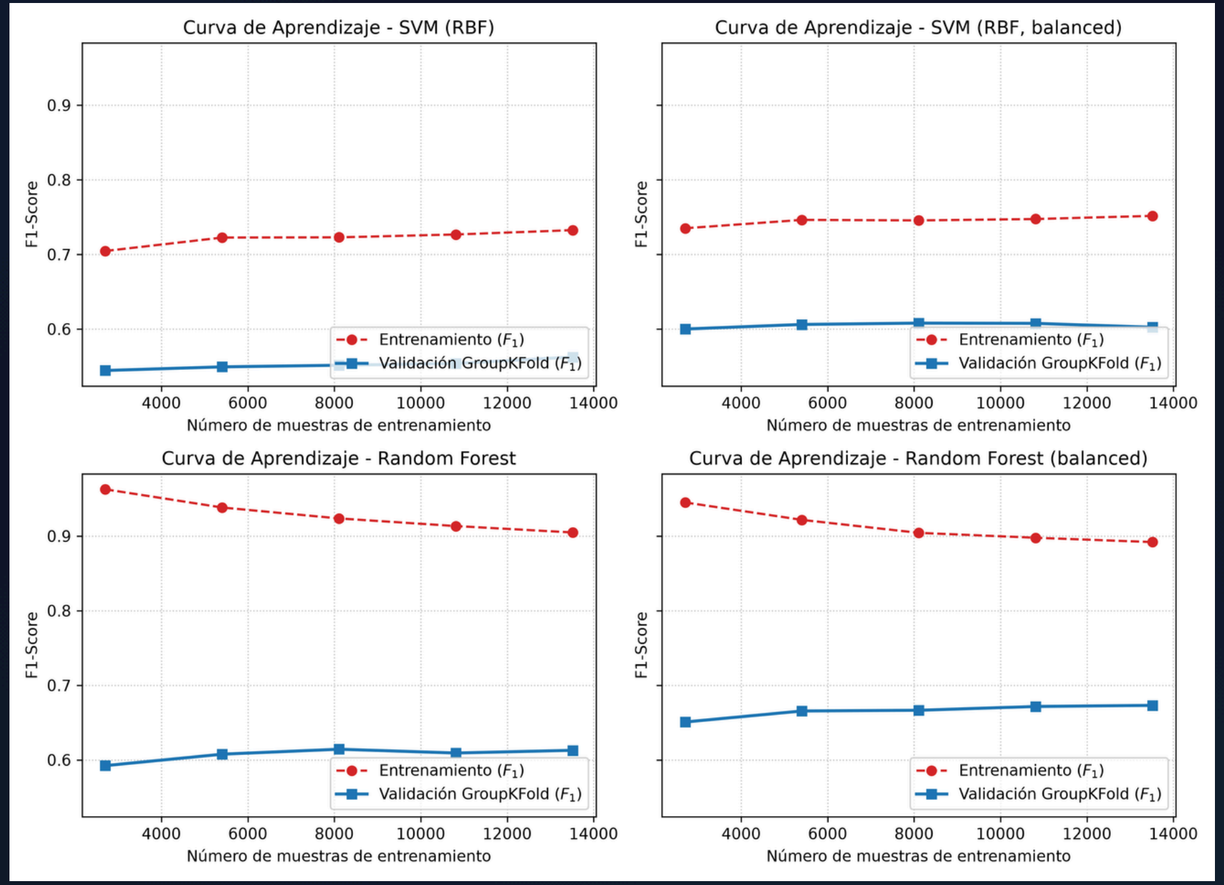


Curvas de Aprendizaje y Límites del Modelo

Equipo A



Equipo B



Escalamiento de la Validación Cruzada

Resultados de aceleración

Equipo A (Ryzen 7): Mostró una reducción de tiempo clara, logrando speedups de 3.62x hasta 4.59x, lo que representa una eficiencia destacable de entre el 72% y el 92% respecto al máximo posible de 5 núcleos.

Equipo B (Ryzen 5): Presentó una aceleración más moderada (de 1.43x a 2.74x).

Límite estructural: Al dividir los datos en 5 particiones por paciente, el sistema lanza exactamente 5 procesos simultáneos, lo que representa el tope máximo de escalamiento para esta etapa.

Nivel de partición: A diferencia de la extracción (que se divide por ventanas), el entrenamiento se paraleliza repartiendo los folds del GroupKFold.

Limitaciones y Trabajo a futuro

Desempeño Diagnóstico y Variabilidad

- Techo predictivo: El modelo alcanzó un F1-Score de 0.686, un valor moderado que se mantiene por debajo de las métricas más altas reportadas en la literatura del estado del arte.
- Dependencia del paciente: La alta desviación estándar del F1 entre los distintos folds (hasta 0.14) demuestra una gran variabilidad.

Control de Falsos Negativos

- El tope del 50%: Al escalar el procesamiento por encima de los núcleos físicos de las máquinas, la eficiencia paralela cayó y se estabilizó cerca del 50%.
- Hipótesis del SMT: Se teoriza que esta pérdida de rendimiento ocurre porque los hilos lógicos (SMT) comparten recursos de ejecución en el procesador, además de posibles estrangulamientos térmicos,

🏁 Conclusiones

Viabilidad del Cómputo en CPU

- Superación del cuello de botella: El sistema demostró que la extrema complejidad de la Entropía Muestral O(N^2) puede resolverse eficazmente desde la ingeniería de software, particionando las ventanas y evadiendo el GIL de Python con multiprocessing nativo.
- Independencia de GPU: Se comprobó que no es estrictamente necesario recurrir a modelos opacos de Deep Learning ni a tarjetas gráficas especializadas para procesar bioseñales complejas a gran escala.

Éxito en la Aceleración Computacional (HPC)

- Metas superadas: El pipeline logró acelerar la extracción de características hasta 7.04x (reduciendo el tiempo en un ~85% en el Equipo A), superando con éxito la meta proyectada en la fase anterior (que era de 3.5x con 4 procesos).

INSTITUTO POLITÉCNICO NACIONAL

¿Preguntas o Comentarios?

Detección Paralela de Apnea del Sueño mediante Extracción de Descriptores Fisiológicos y Aprendizaje Computacional Clásico en CPU

jassieluna2005@gmail.com | dandonado300@gmail.com

Entorno Experimental Heterogéneo

Sistema Portátil

BAJO CONSUMO

CPU: AMD Ryzen 7 5700U (8 núcleos físicos / 16 hilos, arquitectura Zen 2).

Memoria: 16 GB DDR4 a 3200 MHz.

Enfoque Térmico: TDP limitado a 15W, simulando el comportamiento térmico y energético de un monitor ambulatorio bajo carga continua.

Esquema de Prueba: Evaluación común en $P \in \{1, 2, 4\}$ y régimen de saturación física máxima en $P = 8$ workers.

Sistema Portátil

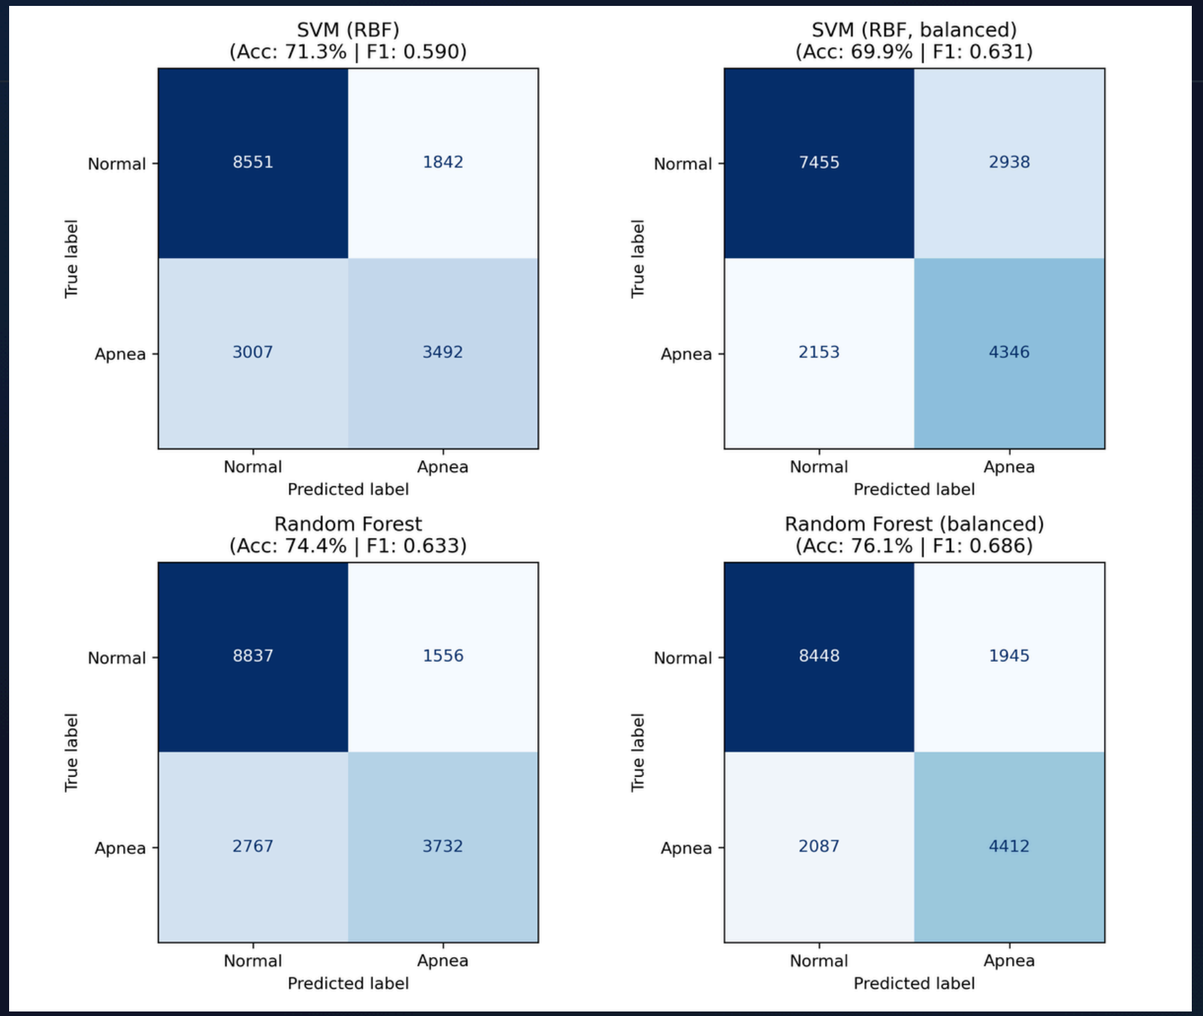
ALTO CONSUMO

CPU: AMD Ryzen 5 240 (6 núcleos físicos / 12 hilos, arquitectura Zen 4).

Memoria: 16 GB DDR5 de alto ancho de banda.

Rendimiento Sostenido: TDP holgado de hasta 45W con caché L3 ampliada.

Esquema de Prueba: Evaluación común en $P \in \{1, 2, 4\}$ y régimen de saturación física máxima en $P = 6$ workers.


SVM (RBF)
(Acc: 71.3% | F1: 0.590)
Normal
Apnea
True label
8551
1842
3007
3492
Normal
Apnea
Predicted label
SVM (RBF, balanced)
(Acc: 69.9% | F1: 0.631)
Normal
Apnea
True label
7455
2938
2153
4346
Normal
Apnea
Predicted label
Random Forest
(Acc: 74.4% | F1: 0.633)
Normal
Apnea
True label
8837
1556
2767
3732
Normal
Apnea
Predicted label
Random Forest (balanced)
(Acc: 76.1% | F1: 0.686)
Normal
Apnea
True label
8448
1945
2087
4412
Normal
Apnea
Predicted label

Dilema en la Literatura Actual

Aprendizaje Profundo (DL)

Dependencia de aceleración GPU: Algunos enfoques de Deep Learning requieren aceleración gráfica, dificultando su despliegue eficiente en dispositivos de bajo consumo.

Opacidad Clínica (Caja Negra): Ausencia de interpretabilidad en la correlación entre activación de capas y el fenómeno fisiológico.

Despliegue en dispositivos de bajo consumo: La carga paramétrica y dependencia de GPU dificultan la ejecución eficiente local.

Modelos Clásicos Monohilo

Cuello de botella $O(N^2)$: El cálculo secuencial de SampEn presenta una elevada latencia al procesar series continuas extensas.

Limitación identificada: Varios trabajos reportan principalmente métricas diagnósticas sin evaluar de forma explícita el coste computacional y la latencia.

Desperdicio de Recursos: Subutilización crítica de los múltiples núcleos físicos disponibles en CPUs comerciales modernas.

Contenido de la Presentación

01. Contexto & Reto

Limitaciones de la Polisomnografía clínica frente a la alternativa del ECG monopolar ambulatorio.

Dilema actual: Deep Learning vs Métodos Clásicos.

02. Metodología

Descomposición de dominio temporal, despachador nativo en CPU sin GIL ni librerías opacas.

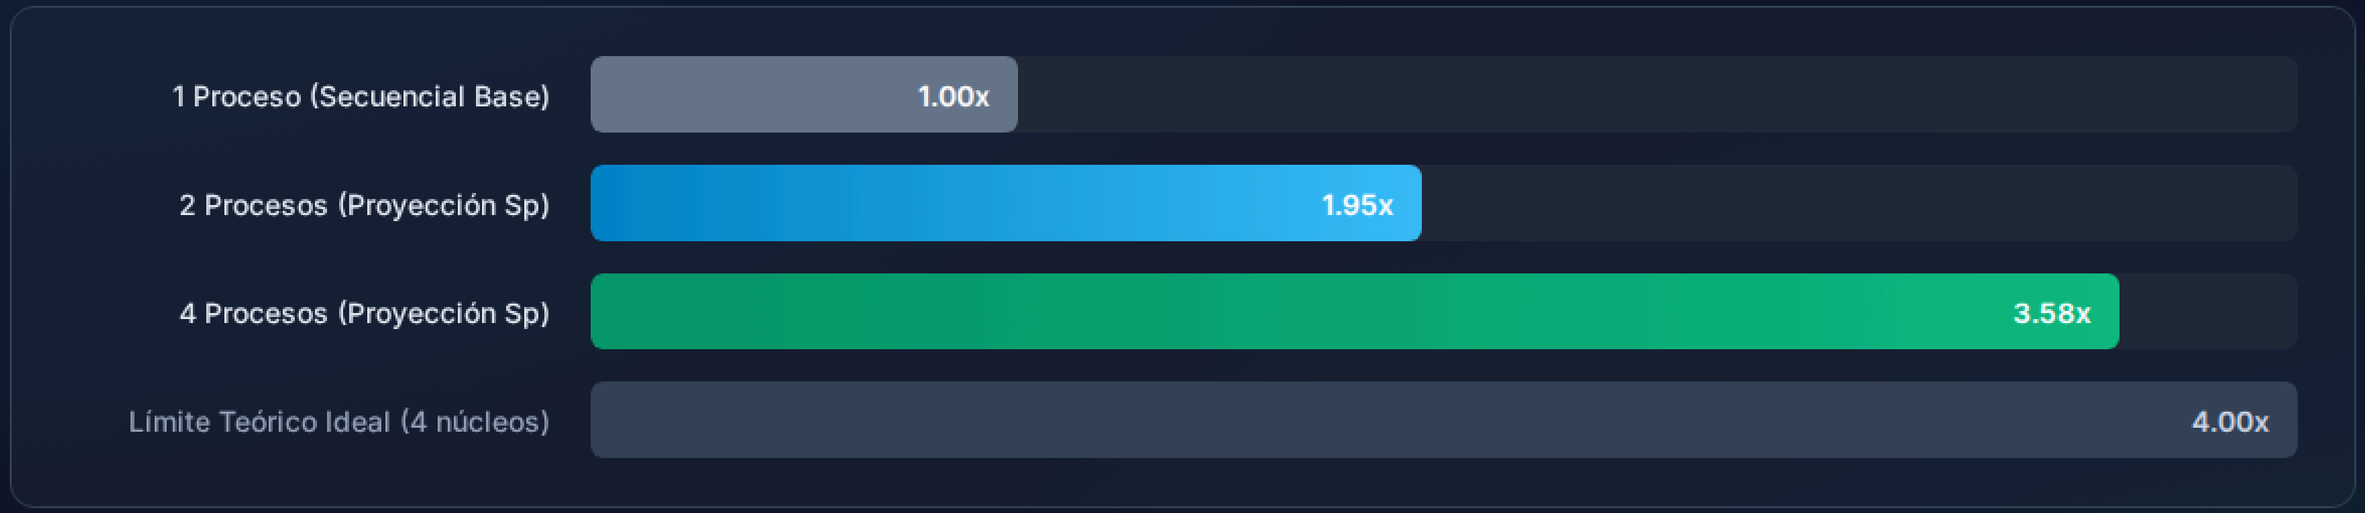
Extracción de HRV, FFT y SampEn $O(N^2)$.

03. Evaluación y Resultados

Escalamiento computacional (Amdahl) Speedup, eficiencia y desempeño diagnóstico proyectados..

Evaluación heterogénea Zen 2 vs Zen 4.

RESULTADOS ESPERADOS — NO MEDIDOS



Nota metodológica: Valores etiquetados como proyecciones de diseño de ingeniería según la fracción paralelizable estimada de SampEn y FFT.