
Detección Paralela de Apnea del Sueño mediante Extracción de Descriptores Fisiológicos y Aprendizaje Computacional Clásico en CPU

Jassiel Luna Cantu

Posgrado en Cómputo / Ingeniería
Instituto Politécnico Nacional
jassieluna2005@gmail.com

Juan Daniel García Román

Posgrado en Cómputo / Ingeniería
Instituto Politécnico Nacional
dandonado300@gmail.com

Repositorio GitHub: <https://github.com/Jazzieluna/computo-paralelo-apnea-ecg.git>

Abstract

El síndrome de apnea obstructiva del sueño (AOS) representa un trastorno respiratorio crítico con severas repercusiones cardiovasculares, cuyo diagnóstico estándar mediante polisomnografía resulta invasivo, lento y de elevado coste clínico. Si bien el análisis de señales de electrocardiograma (ECG) monopolar acoplado a técnicas de aprendizaje automático surge como una alternativa viable, la literatura dominante descansa en arquitecturas opacas de aprendizaje profundo de alto consumo energético, o bien en flujos estadísticos secuenciales que desestiman por completo la latencia y la eficiencia computacional. El cómputo paralelo en memoria compartida ofrece una solución prometedora para mitigar estos cuellos de botella sin depender de aceleradores gráficos. Primero, particionamos series continuas de la base Apnea-ECG en épocas independientes de 60 segundos bajo un esquema de descomposición de dominio. Luego, paralelizamos la extracción simultánea de descriptores temporales de variabilidad cardíaca, densidad espectral vía FFT y entropía muestral (SampEn) empleando un despachador de procesos nativo, acoplándolos posteriormente a clasificadores supervisados clásicos (SVM y ensamble de árboles). De acuerdo con las proyecciones experimentales, nuestro enfoque busca alcanzar un escalamiento sublineal con una ganancia de velocidad (S_P) superior a $3.5\times$ en entornos de 4 núcleos, manteniendo un rendimiento diagnóstico robusto con $F_1 \geq 0.86$ bajo validación independiente.

1 Introducción

El Síndrome de Apnea Obstructiva del Sueño (*Obstructive Sleep Apnea*, OSA) representa un trastorno respiratorio severo caracterizado por episodios recurrentes de colapso parcial o total de la vía aérea superior durante el descanso nocturno. Esta interrupción continua induce hipoxemia transitoria y fragmentación del sueño, conllevando un riesgo elevado de complicaciones cardiovasculares graves [1, 2]. El procedimiento estándar para su diagnóstico definitivo es la Polisomnografía (*Polysomnography*, PSG), la cual evalúa múltiples canales fisiológicos de manera concurrente. No obstante, la PSG constituye una técnica de elevado coste clínico, invasiva y limitada por la disponibilidad de laboratorios especializados [1, 5].

Para mitigar estas limitantes, se ha propuesto el análisis de bioseñales simplificadas, donde el Electrocardiograma (*Electrocardiogram*, ECG) monopolar se posiciona como el canal más informativo debido a las alteraciones directas que la apnea induce sobre el sistema nervioso autónomo [2, 5]. Diversos trabajos han abordado este problema mediante técnicas de Aprendizaje Automático (*Machine Learning*, ML) y Aprendizaje Profundo (*Deep Learning*, DL). Algunos esquemas emplean Redes Neuronales Convolucionales (*Convolutional Neural Networks*, CNN) o modelos recurrentes para aprender representaciones espectrales latentes de forma end-to-end (e.g., [6]). Sin embargo, estos esquemas conllevan una elevada carga paramétrica, opacidad interpretativa (cajas negras) y una estricta dependencia de unidades de procesamiento gráfico (*Graphics Processing Units*, GPU), lo que dificulta su ejecución eficiente en dispositivos locales de bajo consumo.

Por otro lado, los enfoques fundamentados en modelos clásicos de aprendizaje automático como Máquinas de Vectores de Soporte (*Support Vector Machines*, SVM) o Bosques Aleatorios (*Random Forest*, RF) se basan en la extracción manual de características de Variabilidad de la Frecuencia Cardíaca (*Heart Rate Variability*, HRV) y descriptores no lineales como la Entropía Muestral (*Sample Entropy*, SampEn) [3, 4, 7–10]. No obstante, un problema persistente con estas metodologías radica en su formulación computacional estrictamente monohilo; el cálculo de operadores complejos como la Transformada Rápida de Fourier (*Fast Fourier Transform*, FFT) y en particular la SampEn sobre extensas series continuas de tiempo demanda una latencia de cálculo considerable que compromete el análisis en tiempo real. En lugar de diseñar clasificadores predictivos aislados o depender de librerías de aceleración automática como *joblib*, en este trabajo abordamos el cuello de botella computacional desde la perspectiva del cómputo paralelo en memoria compartida implementado de forma nativa en CPU.

En este trabajo proponemos una arquitectura concurrente modular y desacoplada para la extracción y clasificación de eventos de apnea minuto a minuto a partir de bioseñales de ECG de derivación única. El método propuesto particiona las señales continuas de la base de datos *Apnea-ECG* de PhysioNet en épocas independientes de 60 segundos ($N = 6000$ muestras a 100 Hz) bajo un esquema de descomposición de dominio (*domain decomposition*). Posteriormente, implementamos un despachador nativo de procesos worker (*multiprocessing*) que evade el Bloqueo Global del Intérprete (*Global Interpreter Lock*, GIL), permitiendo la extracción paralela y balanceada de tres familias de características fisiológicas: estadísticas temporales de HRV, potencia espectral multi-espectral mediante FFT y la SampEn. La representación compacta resultante alimenta clasificadores supervisados clásicos (SVM y RF), preservando la interpretabilidad biomédica y prescindiendo de infraestructuras aceleradoras costosas.

Reportamos una evaluación formal orientada a la ingeniería de sistemas y a la exactitud diagnóstica. De acuerdo con los objetivos proyectados, nuestro enfoque persigue alcanzar una aceleración sublineal cuantificada con un *speedup* (S_P) superior a $3.5\times$ en entornos comerciales de cuatro núcleos físicos, reduciendo la latencia de procesamiento de registros nocturnos completos sin degradación en la fiabilidad médica, proyectando un puntaje $F_1 \geq 0.86$ bajo esquemas de validación cruzada independiente.

2 Trabajos Relacionados

Diversos enfoques han sido propuestos para la detección automática de episodios de apnea a partir de bioseñales simplificadas de electrocardiograma monopolar. Un grupo representativo de trabajos se fundamenta en la extracción clásica de características en el dominio temporal y frecuencial de la variabilidad del ritmo cardíaco (*Heart Rate Variability*, HRV) combinada con clasificadores de ensamble. Por ejemplo, Fujiwara et al. [5] implementaron un esquema de cribado basado en ventanas móviles acoplado a un modelo de Bosques Aleatorios (*Random Forest*, RF), mientras que Hassan y Haque [4] propusieron el uso de técnicas de remuestreo (*bootstrap aggregating*, Bagging) sobre descriptores espectrales y coeficientes wavelet. De manera complementaria, Sharma et al. [10] extendieron este análisis comparando múltiples arquitecturas de aprendizaje automático clásico frente a registros multimodales. No obstante, estos esquemas presentan limitaciones críticas: dependen preponderantemente de descriptores lineales que desestiman la dinámica no estacionaria de la señal cardíaca, asumen flujos de ejecución monohilo y omiten por completo la evaluación del coste computacional y la latencia de procesamiento.

Otra vertiente destacada en la literatura recurre al modelado matemático de la complejidad fisiológica mediante dinámicas no lineales y descomposiciones espectro-temporales avanzadas. Rajesh et al. [8] aplicaron la Transformada Wavelet Discreta (*Discrete Wavelet Transform*, DWT) junto con medidas de dinámica no lineal acopladas a clasificadores tipo GentleBoost, mientras que Sharma y Sharma [3] exploraron funciones de base Hermite para modelar el complejo QRS sobre Máquinas de Vectores de Soporte de Mínimos Cuadrados (LS-SVM). Asimismo, trabajos como el de Attar [9] incorporaron parámetros de gráficos de Poincaré y entropías para maximizar la separabilidad estadística minuto a minuto. Sin embargo, tales transformaciones analíticas conllevan una complejidad computacional elevada que escala desfavorablemente con la longitud de las series continuas; el cálculo iterativo sobre ventanas prolongadas genera cuellos de botella severos que estos estudios no abordan, limitándose a reportar métricas de exactitud predictiva diagnóstica.

En contraposición a los métodos basados en ingeniería manual de características, se han formulado esfuerzos orientados al aprendizaje automático profundo (*Deep Learning*). Wang et al. [6] diseñaron una Red Neuronal Convolutiva (CNN LeNet-5 modificada) para aprender representaciones espectrales latentes directamente a partir de intervalos RR y amplitudes de picos R de la base *Apnea-ECG*. Aunque estos modelos suprimen el diseño manual de descriptores, padecen de una elevada carga paramétrica, opacidad en la inferencia clínica y una dependencia forzosa de aceleración por unidades de procesamiento gráfico (GPU), lo que compromete su despliegue en dispositivos médicos portátiles o de cómputo en el borde. En contraste con estos trabajos, nuestra propuesta prescinde de arquitecturas neuronales opacas y rescata la explicabilidad de los descriptores matemáticos, resolviendo la sobrecarga de cálculo mediante ejecución concurrente nativa en CPU.

El trabajo más cercano a nuestra propuesta es el desarrollado por Bsoul et al. [1] y complementado por Padovano et al. [7], quienes combinan descriptores temporales, transformadas espectrales y la formulación no lineal de la Entropía Muestral (*Sample Entropy*, SampEn) sobre la base *Apnea-ECG*, alimentando clasificadores SVM con formulación dual cuadrática. A pesar de su solidez teórica, el cálculo de la SampEn presenta una complejidad temporal inherente de orden cuadrático $\mathcal{O}(N^2)$ que vuelve prohibitivo el análisis secuencial de registros nocturnos continuos. Para superar esta limitación, en este trabajo implementamos un esquema de descomposición de dominio particionado en épocas independientes de 60 segundos ($N = 6000$ muestras), acoplado a un despachador nativo de procesos worker que evade el Bloqueo Global del Intérprete (GIL), paralelizando concurrentemente la FFT y la SampEn sin utilizar librerías de aceleración automática como `joblib`.

Table 1: Taxonomía comparativa del estado del arte en detección de apnea del sueño frente a la arquitectura propuesta.

Referencia	Base de Datos	Modalidad de Señal	Extracción de Características	Clasificador ML	Esquema de Cómputo	Rendimiento Reportado
Bsoul et al. (2011)	Apnea-ECG	ECG monopolar	DWT (Wavelet), EDR, HRV temporal	SVM (Kernel RBF / Lineal)	Secuencial (optimizado móvil)	Acc: 89.0%, Sens: 90.0%
Song et al. (2016)	Apnea-ECG	ECG monopolar	HRV temporal y frecuencial	HBM + SVM	Secuencial	Acc: 86.2%, Sens: 82.6%
Sharma & Sharma (2016)	Apnea-ECG	ECG monopolar	Funciones de base Hermite	LS-SVM	Secuencial	Acc: 83.8%, Sens: 79.5%
Hassan & Haque (2016)	Apnea-ECG	ECG monopolar	Descriptores espectrales y estadísticos	Bagging (Decision Trees)	Secuencial	Acc: 85.97%, Sens: 84.14%
Fujiwara et al. (2019)	Apnea-ECG	ECG monopolar	HRV espectral (LF/HF, PSD) y temporal	Random Forest	Secuencial	Acc: 86.4%, Sens: 83.3%
Wang et al. (2019)	Apnea-ECG / UCD	ECG monopolar	Detección de picos R, intervalos RR	CNN (LeNet-5 modificado)	Aceleración GPU (DL)	Acc: 87.6%, Sens: 83.1%
Padovano et al. (2022)	Apnea-ECG	ECG monopolar	Entropía no lineal (SampEn, RP)	SVM / k-NN	Secuencial	AUC: 0.93, F1: 0.88
Rajesh et al. (2021)	Apnea-ECG / UCD	ECG monopolar	DWT (subbandas D_1-D_8) y entropías	GentleBoost / k-NN	Secuencial	Acc: 92.5%, Sens: 91.5%
Attar (2023)	Apnea-ECG	ECG monopolar	HRV no lineal (SampEn, ApEn, SD1/SD2)	XGBoost / Random Forest	Secuencial (CPU monohilo)	AUC: 0.98, Acc: 91.2%
Sharma et al. (2024)	SHHS / NSRR	ECG + SpO ₂	Oximetría (ΔSpO_2) y HRV temporal	Random Forest / XGBoost	Secuencial / scikit-learn	Acc: 88.5%, F1: 0.89
Propuesta de este trabajo	Apnea-ECG (PhysioNet)	ECG monopolar (Derivación única)	Estadísticas temporales, FFT y entropía no lineal (SampEn)	Ensamble Bagging / Random Forest / SVM	Paralelismo nativo en CPU (multiprocessing sin joblib)	Objetivo: S_P sublineal, F1 ≥ 0.86 en validación externa

3 Metodología Propuesta




Figure 1: Diagrama de bloques de la arquitectura concurrente para detección de apnea del sueño sobre CPU multinúcleo en memoria compartida.

La arquitectura propuesta se segmenta en las siguientes fases secuenciales: ingesta y acondicionamiento temporal de la señal fisiológica, extracción de descriptores mediante particionado de datos concurrente y entrenamiento supervisado interpretable.

3.1 Acondicionamiento y Particionado de Señales

Se utiliza la base de datos pública *Apnea-ECG* de PhysioNet, consistente en 70 registros digitalizados a una frecuencia de muestreo $f_s = 100$ Hz. La señal continua $x[n]$ se descompone en épocas discretas uniformes de longitud $T_w = 60$ s ($N = 6000$ muestras por bloque), alineadas con las etiquetas de referencia anotadas minuto a minuto por médicos especialistas.

3.2 Extracción Paralela de Descriptores

Para evitar el uso de librerías automáticas restringidas (`joblib` o `n_jobs`), el paralelismo se estructura manualmente dividiendo el lote de K ventanas entre P procesos worker del sistema. El grado de paralelismo se evalúa con $P \in \{1, 2, 4\}$ procesos worker, permitiendo una comparación directa del rendimiento entre los dos sistemas de prueba utilizados. Para cada ventana se extraen:

1. **Métricas Temporales de HRV:** Estimación de picos R y variaciones en los intervalos entre latidos adyacentes (NN). Se calcula el valor medio (μ_{NN}), desviación estándar ($SDNN$) y raíz del valor cuadrático medio de las diferencias sucesivas ($RMSSD$):

$$RMSSD = \sqrt{\frac{1}{M-1} \sum_{i=1}^{M-1} (NN_{i+1} - NN_i)^2} \quad (1)$$

2. **Potencia Espectral (FFT):** Integración espectral en las bandas fisiológicas de baja frecuencia ($LF \in [0.04, 0.15]$ Hz) y alta frecuencia ($HF \in [0.15, 0.40]$ Hz), computando la razón de modulación autonómica LF/HF .
3. **Entropía Muestral (SampEn):** Cuantificación del grado de auto-similitud sobre secuencias vectoriales de dimensión $m = 2$ y umbral de tolerancia $r = 0.2 \times \sigma$:

$$\text{SampEn}(m, r, N) = -\ln \left(\frac{B^{m+1}(r)}{B^m(r)} \right) \quad (2)$$

3.3 Modelo de Clasificación y Evaluación Paralela

La matriz consolidada de características alimenta modelos de aprendizaje computacional clásico (Support Vector Machines y ensambles Random Forest). La caracterización de rendimiento del sistema computacional se medirá mediante el tiempo secuencial (T_1) frente al tiempo paralelo (T_P), determinando la ganancia de velocidad ($S_P = T_1/T_P$) y la eficiencia ($E_P = S_P/P$) en sistemas de cómputo multicore.

3.4 Entorno experimental

Las pruebas de rendimiento se ejecutan sobre dos sistemas heterogéneos: el primer equipo (AMD Ryzen 7 5700U, 8 núcleos físicos / 16 hilos, arquitectura Zen 2, 16 GB RAM) y el segundo equipo (AMD Ryzen 5 240, 6 núcleos físicos / 12 hilos, arquitectura Zen 4, 16 GB RAM). Para permitir una comparación directa entre ambos sistemas, el número de procesos worker se evalúa sobre el conjunto común $P \in \{1, 2, 4\}$, complementado con mediciones adicionales en el número máximo de núcleos físicos de cada equipo ($P = 8$ en el sistema portátil, $P = 6$ en el sistema de escritorio) para analizar el comportamiento de saturación específico de cada arquitectura.

4 Resultados Esperados

4.1 Comportamiento Projectado del Speedup (S_P)

Se proyecta un escalamiento **sublineal** de S_P respecto al número de procesos P , consistente con la Ley de Amdahl. La fracción secuencial del pipeline —lectura de disco, particionado inicial de épocas y recolección/concatenación de resultados de los workers— impone un límite teórico superior al speedup alcanzable. Se espera que la ganancia sea más pronunciada en el cálculo de la Entropía Muestral (SampEn), dado su costo computacional cuadrático $O(N^2)$ por ventana, que en la FFT, cuya complejidad $O(N \log N)$ deja menos margen de paralelización relativa. Proyectamos $S_P \approx 1.8 \times - 2.2 \times$ en $P = 2$ y $S_P > 3.5 \times$ en $P = 4$, con una curva que se aleja gradualmente del speedup ideal ($S_P = P$) conforme crece P , producto del overhead de serialización (pickling) de las épocas de 6000 muestras entre procesos.

4.2 Curva de Escalabilidad y Eficiencia (E_P)

En correspondencia con el comportamiento de S_P , se anticipa que la eficiencia $E_P = S_P/P$ decrezca monótonamente a medida que aumenta P , partiendo de $E_1 = 1$ por definición. Se espera una eficiencia cercana a 0.9–0.95 en $P = 2$, degradándose a un rango de 0.85–0.90 en $P = 4$, reflejo del overhead de creación de procesos y de la contención por ancho de banda de memoria al despachar simultáneamente los tres extractores de características. Esta caída se proyecta más marcada en el sistema portátil (Ryzen 7 5700U, TDP de 15W) que en el sistema de escritorio (Ryzen 5 240, TDP de hasta 45W), debido a las limitaciones térmicas propias de un chip de bajo consumo bajo carga sostenida en múltiples núcleos.

4.3 Matriz de Confusión Diagnóstica Proyectada

Dado el objetivo de $F1 \geq 0.86$ bajo validación independiente, se proyecta una matriz de confusión con fuerte dominancia diagonal (alta concordancia entre las clases predichas y las anotaciones de referencia minuto a minuto). Consistente con la literatura revisada (Tabla 1), se anticipa un mayor riesgo de falsos negativos que de falsos positivos, dado que los eventos de apnea leve pueden presentar variaciones de HRV sutiles y solaparse con ruido fisiológico normal. Priorizamos minimizar este error en particular, ya que en un contexto clínico un falso negativo (apnea no detectada) tiene mayor costo que un falso positivo, lo que orientará el ajuste del umbral de decisión del clasificador durante la fase de validación.

5 Conclusiones Preliminares

El presente trabajo aborda una limitante crítica identificada de forma recurrente en el estado del arte (Sección 2): la complejidad temporal cuadrática $O(N^2)$ del cálculo de la Entropía Muestral (SampEn) impone un cuello de botella severo que trabajos previos como Bsoul et al. [1] y Padovano et al. [7] no resuelven, limitándose a reportar métricas de exactitud diagnóstica sin considerar el costo computacional del procesamiento. Frente a este vacío, y a diferencia de los enfoques basados en aprendizaje profundo que trasladan el problema hacia la dependencia de aceleradores gráficos [6], la arquitectura propuesta mitiga el cuello de botella desde la ingeniería del sistema: mediante un esquema de descomposición de dominio que particiona las series continuas en épocas independientes de 60 segundos, y un despachador nativo de procesos worker que evade el Bloqueo Global del Intérprete (GIL), es posible extraer de forma concurrente los tres descriptores fisiológicos —temporales, espectrales y de entropía no lineal— sin recurrir a librerías de aceleración automática restringidas (joblib, n_jobs) ni a infraestructura de cómputo especializada.

Esta estrategia preserva las dos propiedades que la literatura clásica sacrifica una a costa de la otra: la interpretabilidad biomédica de los descriptores manuales frente a las arquitecturas de caja negra, y la viabilidad computacional en hardware de bajo consumo frente a los esquemas secuenciales monohilo. De confirmarse las proyecciones de escalamiento descritas en la Sección 4 ($S_P > 3.5\times$ en $P = 4$, $F1 \geq 0.86$), el sistema propuesto constituiría una alternativa eficiente y explicable para el cribado de apnea del sueño en dispositivos de cómputo local, evitando la dependencia de GPU y de infraestructuras clínicas costosas. Los resultados obtenidos sobre la evaluación comparativa entre los dos sistemas de prueba (Sección 3.4) permitirán, en la siguiente entrega del proyecto, contrastar estas proyecciones contra mediciones reales y refinar el balance entre paralelismo, latencia y fiabilidad diagnóstica.

References

- [1] M. Bsoul, H. Minn, and L. Tamil. Apnea MedAssist: Real-time sleep apnea monitor using single-lead ECG. *IEEE Transactions on Information Technology in Biomedicine*, 15(3):416–427, 2011.
- [2] C. Song, K. Liu, X. Zhang, L. Chen, and X. Xian. An obstructive sleep apnea detection approach using support vector machine based on ECG signals. *Journal of Medical Systems*, 40(6):136, 2016.
- [3] H. Sharma and K. K. Sharma. An efficient method for sleep apnea detection using Hermite basis functions on ECG signals. *Fluctuation and Noise Letters*, 15(03):1650022, 2016.
- [4] A. R. Hassan and M. A. Haque. An expert system for automated detection of obstructive sleep apnea from single-lead ECG using dual-tree complex wavelet transform. *Biomedical Signal Processing and Control*, 24:62–71, 2016.
- [5] K. Fujiwara, M. Kano, and H. Kadotani. Obstructive sleep apnea screening based on HRV analysis and machine learning. *Scientific Reports*, 9(1):1–9, 2019.
- [6] T. Wang, C. Lu, G. Shen, and F. Hong. Sleep apnea detection from a single-lead ECG signal with automatic feature-extraction through a modified LeNet-5 convolutional neural network. *PeerJ*, 7:e7731, 2019.

- [7] D. Padovano et al. Sample entropy and recurrence quantification analysis of heart rate variability for sleep apnea screening. *IEEE Access*, 10:14512–14523, 2022.
- [8] K. N. V. P. S. Rajesh, R. Dhuli, and C. Varon. Sleep apnea detection using discrete wavelet transform and non-linear dynamics from single-lead ECG. *Biomedical Signal Processing and Control*, 68:102710, 2021.
- [9] E. T. Attar. Detailed evaluation of sleep apnea using heart rate variability: A machine learning and statistical method using ECG data. *Frontiers in Digital Health*, 5:1145213, 2023.
- [10] V. Sharma, M. A. Islam, U. Goswami, C. M. Ruoff, and M. M. H. Shandhi. Comparative analysis of machine learning models for obstructive sleep apnea detection using pulse oximetry and heart rate variability. *IEEE Journal of Biomedical and Health Informatics*, 28(4):2130–2141, 2024.