

---

# Detección Paralela de Apnea del Sueño mediante Extracción de Descriptores Fisiológicos y Aprendizaje Computacional Clásico en CPU

---

**Jassiel Luna Cantu**

Posgrado en Cómputo / Ingeniería  
Instituto Politécnico Nacional  
jassieluna2005@gmail.com

**Juan Daniel García Román**

Posgrado en Cómputo / Ingeniería  
Instituto Politécnico Nacional  
dandonado300@gmail.com

Repositorio GitHub: <https://github.com/Jazzieluna/computo-paralelo-apnea-ecg.git>

## Abstract

La apnea del sueño es un trastorno común en donde la respiración se interrumpe o se hace muy superficial. Estas interrupciones pueden durar desde unos pocos segundos a minutos y pueden ocurrir más de 30 veces por hora y para diagnosticarla se requiere realizar una polisomnografía que es muy invasiva, y cara. Y, aunque el análisis de señales de electrocardiograma (ECG) que se aplican a técnicas de aprendizaje automático es una opción, muchos artículos utilizan arquitecturas de aprendizaje profundo de alto consumo energético, o también en procesos secuenciales que pueden llegar a ser muy tardados y demandantes de poder de cómputo. El cómputo paralelo en memoria compartida ofrece una solución prometedora para tratar este problema sin depender de aceleradores gráficos. Primero, particionamos series continuas de la base Apnea-ECG en épocas independientes de 60 segundos bajo un esquema de descomposición de dominio. Luego, paralelizamos la extracción simultánea de descriptores temporales de variabilidad cardíaca, densidad espectral vía FFT y entropía muestral (SampEn) empleando un despachador de procesos nativo, acoplándolos posteriormente a clasificadores supervisados clásicos (SVM y ensamble de árboles). De acuerdo con las proyecciones experimentales, nuestro procedimiento busca alcanzar un escalamiento sublineal con una ganancia de velocidad ( $S_P$ ) superior a  $3.5\times$  en entornos de 4 núcleos, manteniendo un rendimiento diagnóstico robusto con  $F_1 \geq 0.86$  bajo validación independiente.

## 1 Introducción

El síndrome de apnea obstructiva del sueño es un problema respiratorio en el que la vía aérea se cierra una y otra vez mientras la persona duerme. Esto provoca que el cuerpo se quede sin suficiente oxígeno por momentos y que el sueño se interrumpa constantemente, lo cual con el tiempo puede derivar en complicaciones serias para el corazón. La manera "oficial" de detectarlo es a través de un estudio del sueño que analiza al paciente durante toda la noche conectado a varios sensores, pero se trata de un procedimiento costoso, incómodo y que no está disponible en cualquier lugar.

Por eso se ha buscado la forma de simplificar el proceso apoyándose en una sola señal: la actividad eléctrica del corazón, que resulta especialmente útil porque la apnea deja huellas claras en cómo el

sistema nervioso regula los latidos. Se han probado distintas formas de abordar esto con inteligencia artificial. Algunas usan redes neuronales que aprenden por sí solas a reconocer patrones en la señal, pero suelen ser pesadas, difíciles de interpretar y casi siempre necesitan hardware especializado para funcionar con fluidez.

Otro camino, más tradicional, consiste en extraer a mano ciertas características de la variabilidad del ritmo cardíaco y de qué tan "irregular" o "predecible" se comporta la señal en el tiempo. El inconveniente aquí es que estos cálculos, en particular los que miden la complejidad de la señal, suelen tardar bastante cuando se hacen de la forma habitual, uno tras otro, lo que complica cualquier intento de análisis rápido o en tiempo real. En este trabajo no se propone simplemente otro modelo más para clasificar, sino que se ataca el problema desde otro ángulo: repartir el trabajo entre varios procesos que corran al mismo tiempo dentro del propio procesador, sin depender de soluciones automáticas ya hechas.

La idea central es tomar las señales continuas de una base de datos conocida de estudios de sueño y dividir las en fragmentos de un minuto cada uno. Después, en lugar de procesar todo de manera secuencial, se reparte el trabajo entre distintos procesos que corren en paralelo, cada uno encargándose de una parte de la extracción de características: unas relacionadas con el comportamiento general del ritmo cardíaco, otras con su contenido de frecuencias, y otras con qué tan regular o caótica es la señal. Con esa información ya resumida, se entrenan modelos de clasificación más sencillos, de los que se pueden interpretar, evitando así recurrir a equipos costosos.

Al final, lo que se busca demostrar no es solo qué tan bien clasifica el sistema, sino qué tanto se gana en velocidad al repartir el trabajo de esta manera, apuntando a una mejora notable en el tiempo de procesamiento en equipos comunes de varios núcleos, sin que esto sacrifique la confiabilidad de los resultados frente a lo que se espera clínicamente.

## 2 Trabajos Relacionados

Se han encontrado muchos trabajos relacionados con la detección automática de episodios de apnea a partir de bioseñales simplificadas de electrocardiograma monopolar. La mayoría de ellos se basa en la extracción clásica de características en el dominio temporal y frecuencial de la variabilidad del ritmo cardíaco (*Heart Rate Variability*, HRV) combinada con clasificadores de ensamble. Por ejemplo, Fujiwara et al. [5] implementaron un esquema de cribado basado en ventanas móviles acoplado a un modelo de Bosques Aleatorios (*Random Forest*, RF), mientras que Hassan y Haque [4] propusieron el uso de técnicas de remuestreo (*bootstrap aggregating*, Bagging) sobre descriptores espectrales y coeficientes wavelet. De manera complementaria, Sharma et al. [10] extendieron este análisis comparando múltiples arquitecturas de aprendizaje automático clásico frente a registros multimodales. No obstante, estos esquemas presentan limitaciones críticas: dependen preponderantemente de descriptores lineales que desestiman la dinámica no estacionaria de la señal cardíaca, asumen flujos de ejecución monohilo y omiten por completo la evaluación del coste computacional y la latencia de procesamiento.

En otro trabajo se ve una inclinación al modelado matemático de la complejidad fisiológica mediante dinámicas no lineales y descomposiciones espectro-temporales avanzadas. Rajesh et al. [8] aplicaron la Transformada Wavelet Discreta (*Discrete Wavelet Transform*, DWT) junto con medidas de dinámica no lineal acopladas a clasificadores tipo GentleBoost, mientras que Sharma y Sharma [3] exploraron funciones de base Hermite para modelar el complejo QRS sobre Máquinas de Vectores de Soporte de Mínimos Cuadrados (LS-SVM). Asimismo, trabajos como el de Attar [9] incorporaron parámetros de gráficos de Poincaré y entropías para maximizar la separabilidad estadística minuto a minuto. Sin embargo, tales transformaciones analíticas conllevan una complejidad computacional elevada que escala desfavorablemente con la longitud de las series continuas; el cálculo iterativo sobre ventanas prolongadas genera cuellos de botella severos que estos estudios no abordan, limitándose a reportar métricas de exactitud predictiva diagnóstica.

También se ha encontrado que se han hecho trabajos orientados al aprendizaje automático profundo (*Deep Learning*). Wang et al. [6] diseñaron una Red Neuronal Convolucional (CNN LeNet-5 modificada) para aprender representaciones espectrales latentes directamente a partir de intervalos RR y amplitudes de picos R de la base *Apnea-ECG*. Aunque estos modelos suprimen el diseño manual de descriptores, padecen de una elevada carga paramétrica, opacidad en la inferencia clínica y una dependencia forzosa de aceleración por unidades de procesamiento gráfico (GPU), lo que dificulta

su despliegue en dispositivos médicos portátiles o de cómputo en el borde. En contraste con estos trabajos, nuestra propuesta no es sobre redes neuronales, por otro lado, prevalece la explicabilidad de los descriptores matemáticos, resolviendo la sobrecarga de cálculo mediante ejecución concurrente nativa en CPU.

El trabajo más cercano al nuestro es el desarrollado por Bsoul et al. [1] y Padovano et al. [7], quienes combinan descriptores temporales, transformadas espectrales y la formulación no lineal de la Entropía Muestral (*Sample Entropy*, SampEn) sobre la base *Apnea-ECG*, alimentando clasificadores SVM con formulación dual cuadrática. Sin embargo, el cálculo de la SampEn presenta una complejidad temporal inherente de orden cuadrático  $\mathcal{O}(N^2)$  que hace muy difícil y tardado el análisis secuencial de registros nocturnos continuos.

Table 1: Taxonomía comparativa del estado del arte en detección de apnea del sueño frente a la arquitectura propuesta.

| Referencia                       | Base de Datos                | Modalidad de Señal                      | Extracción de Características                                     | Clasificador ML                               | Esquema de Cómputo                                            | Rendimiento Reportado                                                                        |
|----------------------------------|------------------------------|-----------------------------------------|-------------------------------------------------------------------|-----------------------------------------------|---------------------------------------------------------------|----------------------------------------------------------------------------------------------|
| Bsoul et al. (2011)              | Apnea-ECG                    | ECG monopolar                           | DWT (Wavelet), EDR, HRV temporal                                  | SVM (Kernel RBF / Lineal)                     | Secuencial (optimizado móvil)                                 | Acc: 89.0%, Sens: 90.0%                                                                      |
| Song et al. (2016)               | Apnea-ECG                    | ECG monopolar                           | HRV temporal y frecuencial                                        | HMM + SVM                                     | Secuencial                                                    | Acc: 86.2%, Sens: 82.6%                                                                      |
| Sharma & Sharma (2016)           | Apnea-ECG                    | ECG monopolar                           | Funciones de base Hermite                                         | LS-SVM                                        | Secuencial                                                    | Acc: 83.8%, Sens: 79.5%                                                                      |
| Hassan & Haque (2016)            | Apnea-ECG                    | ECG monopolar                           | Descriptores espectrales y estadísticos                           | Bagging (Decision Trees)                      | Secuencial                                                    | Acc: 85.97%, Sens: 84.14%                                                                    |
| Fujiwara et al. (2019)           | Apnea-ECG                    | ECG monopolar                           | HRV espectral (L/F/HF, PSD) y temporal                            | Random Forest                                 | Secuencial                                                    | Acc: 86.4%, Sens: 83.3%                                                                      |
| Wang et al. (2019)               | Apnea-ECG / UCD              | ECG monopolar                           | Detección de picos R, intervalos RR                               | CNN (LeNet-5 modificado)                      | Aceleración GPU (DL)                                          | Acc: 87.6%, Sens: 83.1%                                                                      |
| Padovano et al. (2022)           | Apnea-ECG                    | ECG monopolar                           | Entropía no lineal (SampEn, RP)                                   | SVM / k-NN                                    | Secuencial                                                    | AUC: 0.93, F1: 0.88                                                                          |
| Rajesh et al. (2021)             | Apnea-ECG / UCD              | ECG monopolar                           | DWT (subbandas $D_1-D_9$ ) y entropías                            | GentleBoost / k-NN                            | Secuencial                                                    | Acc: 92.5%, Sens: 91.5%                                                                      |
| Attar (2023)                     | Apnea-ECG                    | ECG monopolar                           | HRV no lineal (SampEn, ApEn, SD1/SD2)                             | XGBoost / Random Forest                       | Secuencial (CPU monohilo)                                     | AUC: 0.98, Acc: 91.2%                                                                        |
| Sharma et al. (2024)             | SHHS / NSRR                  | ECG + SpO <sub>2</sub>                  | Oximetría ( $\Delta\text{SpO}_2$ ) y HRV temporal                 | Random Forest / XGBoost                       | Secuencial / scikit-learn                                     | Acc: 88.5%, F1: 0.89                                                                         |
| <b>Propuesta de este trabajo</b> | <b>Apnea-ECG (PhysioNet)</b> | <b>ECG monopolar (Derivación única)</b> | <b>Estadísticas temporales, FFT y entropía no lineal (SampEn)</b> | <b>Ensamble Bagging / Random Forest / SVM</b> | <b>Paralelismo nativo en CPU (multiprocessing sin joblib)</b> | <b>Objetivo: <math>S_P</math> sublineal, F1 <math>\geq 0.86</math> en validación externa</b> |

### 3 Metodología Propuesta




Figure 1: Diagrama de bloques de la arquitectura concurrente para detección de apnea del sueño sobre CPU multinúcleo en memoria compartida.

La arquitectura propuesta se segmenta en las siguientes fases: ingesta y acondicionamiento temporal de la señal fisiológica, extracción de descriptores mediante particionado de datos concurrente y entrenamiento supervisado interpretable.

#### 3.1 Acondicionamiento y Particionado de Señales

Se utiliza la base de datos pública *Apnea-ECG* de PhysioNet, consistente en 70 registros digitalizados a una frecuencia de muestreo  $f_s = 100$  Hz. La señal continua  $x[n]$  se descompone en épocas discretas uniformes de longitud  $T_w = 60$  s ( $N = 6000$  muestras por bloque), alineadas con las etiquetas de referencia anotadas minuto a minuto por médicos especialistas.

#### 3.2 Extracción Paralela de Descriptores

Para no hacer uso de librerías restringidas (joblib o n\_jobs), el paralelismo se estructura manualmente dividiendo el lote de  $K$  ventanas entre  $P$  procesos worker del sistema. El grado de paralelismo se evalúa con  $P \in \{1, 2, 4\}$  procesos worker, permitiendo una comparación directa del rendimiento entre los dos sistemas de prueba utilizados. Para cada ventana se extraen:

1. **Métricas Temporales de HRV:** Estimación de picos  $R$  y variaciones en los intervalos entre latidos adyacentes ( $NN$ ). Se calcula el valor medio ( $\mu_{NN}$ ), desviación estándar ( $SD_{NN}$ ) y raíz del valor cuadrático medio de las diferencias sucesivas ( $RMSSD$ ):

$$RMSSD = \sqrt{\frac{1}{M-1} \sum_{i=1}^{M-1} (NN_{i+1} - NN_i)^2} \quad (1)$$

2. **Potencia Espectral (FFT):** Integración espectral en las bandas fisiológicas de baja frecuencia ( $LF \in [0.04, 0.15]$  Hz) y alta frecuencia ( $HF \in [0.15, 0.40]$  Hz), computando la razón de modulación autonómica  $LF/HF$ .
3. **Entropía Muestral (SampEn):** Cuantificación del grado de auto-similitud sobre secuencias vectoriales de dimensión  $m = 2$  y umbral de tolerancia  $r = 0.2 \times \sigma$ :

$$\text{SampEn}(m, r, N) = -\ln \left( \frac{B^{m+1}(r)}{B^m(r)} \right) \quad (2)$$

### 3.3 Modelo de Clasificación y Evaluación Paralela

La matriz consolidada de características alimenta modelos de aprendizaje computacional clásico (Support Vector Machines y ensambles Random Forest). La caracterización de rendimiento del sistema computacional se medirá mediante el tiempo secuencial ( $T_1$ ) frente al tiempo paralelo ( $T_P$ ), determinando la ganancia de velocidad ( $S_P = T_1/T_P$ ) y la eficiencia ( $E_P = S_P/P$ ) en sistemas de cómputo multicore.

### 3.4 Entorno experimental

Las pruebas de rendimiento se ejecutan sobre dos sistemas heterogéneos: el primer equipo (AMD Ryzen 7 5700U, 8 núcleos físicos / 16 hilos, arquitectura Zen 2, 16 GB RAM) y el segundo equipo (AMD Ryzen 5 240, 6 núcleos físicos / 12 hilos, arquitectura Zen 4, 16 GB RAM). Para permitir una comparación directa entre ambos sistemas, el número de procesos worker se evalúa sobre el conjunto común  $P \in \{1, 2, 4\}$ , complementado con mediciones adicionales en el número máximo de núcleos físicos de cada equipo ( $P = 8$  en el sistema portátil,  $P = 6$  en el sistema de escritorio) para analizar el comportamiento de saturación específico de cada arquitectura.

## 4 Resultados Esperados

### 4.1 Comportamiento Proyectado del Speedup ( $S_P$ )

Esperamos un escalamiento **sublineal** de  $S_P$  respecto al número de procesos  $P$ , consistente con la Ley de Amdahl. La fracción secuencial del pipeline —lectura de disco, particionado inicial de épocas y recolección/concatenación de resultados de los workers— impone un límite teórico superior al speedup alcanzable. Se espera que la ganancia sea más pronunciada en el cálculo de la Entropía Muestral (SampEn), dado su costo computacional cuadrático  $O(N^2)$  por ventana, que en la FFT, cuya complejidad  $O(N \log N)$  deja menos margen de paralelización relativa. Proyectamos  $S_P \approx 1.8 \times - 2.2 \times$  en  $P = 2$  y  $S_P > 3.5 \times$  en  $P = 4$ , con una curva que se aleja gradualmente del speedup ideal ( $S_P = P$ ) conforme crece  $P$ , producto del overhead de serialización (pickling) de las épocas de 6000 muestras entre procesos.

### 4.2 Curva de Escalabilidad y Eficiencia ( $E_P$ )

En el comportamiento de  $S_P$ , se esperamos que la eficiencia  $E_P = S_P/P$  decrezca a medida que aumenta  $P$ , partiendo de  $E_1 = 1$  por definición. Se espera una eficiencia cercana a 0.9–0.95 en  $P = 2$ , degradándose a un rango de 0.85–0.90 en  $P = 4$ , reflejo del overhead de creación de procesos y de la contención por ancho de banda de memoria al despachar simultáneamente los tres extractores de características. Esta caída se proyecta más marcada en el sistema portátil (Ryzen 7 5700U, TDP de 15W) que en el sistema de escritorio (Ryzen 5 240, TDP de hasta 45W), debido a las limitaciones térmicas propias de un chip de bajo consumo bajo carga sostenida en múltiples núcleos.

### 4.3 Matriz de Confusión Diagnóstica Proyectada

Dado el objetivo de  $F1 \geq 0.86$  bajo validación independiente, se proyecta una matriz de confusión con fuerte dominancia diagonal (alta concordancia entre las clases predichas y las anotaciones de referencia minuto a minuto). Consistente con la literatura revisada (Tabla 1), se anticipa un mayor riesgo de falsos negativos que de falsos positivos, dado que los eventos de apnea leve pueden presentar variaciones de HRV sutiles y solaparse con ruido fisiológico normal. Priorizamos minimizar este error en particular, ya que en un contexto clínico un falso negativo (apnea no detectada) tiene mayor costo que un falso positivo, lo que orientará el ajuste del umbral de decisión del clasificador durante la fase de validación.

## 5 Conclusiones Preliminares

Nuestro proyecto se enfoca en una característica en el estado del arte (Sección 2): la complejidad temporal cuadrática  $O(N^2)$  del cálculo de la Entropía Muestral (SampEn) impone un cuello de botella que en los trabajos de Bsoul et al. [1] y Padovano et al. [7] no resuelven, limitándose a reportar métricas de exactitud diagnóstica sin considerar el costo computacional del procesamiento. Frente a este vacío, y a diferencia de los enfoques basados en aprendizaje profundo que trasladan el problema hacia la dependencia de aceleradores gráficos [6], la arquitectura propuesta mitiga el cuello de botella desde la ingeniería del sistema: mediante un esquema de descomposición de dominio en la que se dividen las series continuas en épocas independientes de 60 segundos, y un despachador nativo de procesos worker, es posible extraer de forma concurrente los tres descriptores fisiológicos sin hacer uso de librerías de aceleración automática restringidas (joblib, n\_jobs) ni a infraestructura de cómputo especializada.

Esta estrategia tiene las dos propiedades que la literatura clásica sacrifica una u otra: la interpretabilidad biomédica de los descriptores manuales frente a las arquitecturas de caja negra, y la viabilidad computacional en hardware de bajo consumo frente a los esquemas secuenciales monohilo. De confirmarse las proyecciones de escalamiento descritas en la Sección 4 ( $S_P > 3.5 \times$  en  $P = 4$ ,  $F1 \geq 0.86$ ), el sistema propuesto constituiría una alternativa eficiente y explicable para el cribado de apnea del sueño en dispositivos de cómputo local, evitando la dependencia de GPU y de infraestructuras clínicas costosas. Los resultados obtenidos sobre la evaluación comparativa entre los dos sistemas de prueba (Sección 3.4) permitirán, en la siguiente entrega del proyecto, contrastar estas proyecciones contra mediciones reales y refinar el balance entre paralelismo, latencia y fiabilidad diagnóstica.

## References

- [1] M. Bsoul, H. Minn, and L. Tamil. Apnea MedAssist: Real-time sleep apnea monitor using single-lead ECG. *IEEE Transactions on Information Technology in Biomedicine*, 15(3):416–427, 2011.
- [2] C. Song, K. Liu, X. Zhang, L. Chen, and X. Xian. An obstructive sleep apnea detection approach using support vector machine based on ECG signals. *Journal of Medical Systems*, 40(6):136, 2016.
- [3] H. Sharma and K. K. Sharma. An efficient method for sleep apnea detection using Hermite basis functions on ECG signals. *Fluctuation and Noise Letters*, 15(03):1650022, 2016.
- [4] A. R. Hassan and M. A. Haque. An expert system for automated detection of obstructive sleep apnea from single-lead ECG using dual-tree complex wavelet transform. *Biomedical Signal Processing and Control*, 24:62–71, 2016.
- [5] K. Fujiwara, M. Kano, and H. Kadotani. Obstructive sleep apnea screening based on HRV analysis and machine learning. *Scientific Reports*, 9(1):1–9, 2019.
- [6] T. Wang, C. Lu, G. Shen, and F. Hong. Sleep apnea detection from a single-lead ECG signal with automatic feature-extraction through a modified LeNet-5 convolutional neural network. *PeerJ*, 7:e7731, 2019.
- [7] D. Padovano et al. Sample entropy and recurrence quantification analysis of heart rate variability for sleep apnea screening. *IEEE Access*, 10:14512–14523, 2022.
- [8] K. N. V. P. S. Rajesh, R. Dhuli, and C. Varon. Sleep apnea detection using discrete wavelet transform and non-linear dynamics from single-lead ECG. *Biomedical Signal Processing and Control*, 68:102710, 2021.
- [9] E. T. Attar. Detailed evaluation of sleep apnea using heart rate variability: A machine learning and statistical method using ECG data. *Frontiers in Digital Health*, 5:1145213, 2023.
- [10] V. Sharma, M. A. Islam, U. Goswami, C. M. Ruoff, and M. M. H. Shandhi. Comparative analysis of machine learning models for obstructive sleep apnea detection using pulse oximetry and heart rate variability. *IEEE Journal of Biomedical and Health Informatics*, 28(4):2130–2141, 2024.